



闽江大学
MINJIANG UNIVERSITY

DINOv3 项目复现分享

让模型在没有人工标注时学会看图 · facebookresearch/dinov3

深度学习 · 课堂分享 余官松 · 陈良宇 · 沈逸帆

汇报人：余官松、陈良宇、沈逸帆

2026年9月19日


★ 11.4k Stars

960 Forks

70 Commits

12 Contributors

145 Issues



github.com/facebookresearch/dinov3 · 2025 年 8 月发布 · 截图与数据取自 2026 年 9 月

来源

Meta FAIR 官方实现

PyTorch 代码 + 一组预训练权重，从 21M 的 ViT-S 到 7B 的旗舰模型都可以直接下载使用。

仓库里有什么

模型定义、权重加载、下游示例

分类、分割、深度估计等任务都给了 notebook，改几行就能换成自己的图片。

为什么选它

可运行、可解释、对应课程内容

核心结构是课上讲的 ViT，训练方式是自监督表示学习，Mac 上也能跑。



自上而下：原图 • DINOv2 特征 / mask • DINOv3 特征 / mask

一句话

输入一张图片，输出两种特征：整张图一个向量，每个 16×16 的 patch 各一个向量。

整图特征

描述"这张图是什么"，适合图像分类、以图搜图。

局部特征

保留每个位置的信息，适合分割、深度估计、找主体在哪。

特征是预训练好的，下游任务通常冻结主干，只训练一个小的分类头或分割头，不必从零训练整套模型。

监督预训练的问题

- 需要人工给每张图打标签，量大、贵，而且标注本身带有偏见。
- 模型只学到标签体系里有的概念，换一个任务就要重新标注、重新训练。

DINOv3 的做法：自监督

- 只用无标签图片，让同一张图的不同裁剪版本输出一致的特征。
- 17 亿张图片上学到的是通用的物体与空间结构，而不是某一套标签。

海量无标签图片



自监督预训练



冻结的通用特征



分类 · 分割 · 深度 · 检索

先从无标签图片学通用能力，再迁移到具体任务——一套模型，多种任务。这也是"视觉基础模型"这个词的含义。

① 切块 · ViT

图片变成 token 序列

把图片切成 16×16 的 patch，每个 patch 当作一个 token，送进 Transformer。这是课上讲过的 ViT 结构。

② 对齐 · DINO

学生看局部，老师看整图

同一个网络复制成两份：学生只看小裁剪，老师看整张图，两边都取 **CLS token** 的输出（整图的总结向量），要求一致。老师权重是学生的滑动平均，不反向传播。

③ 提特征

训练完成后冻结使用

输出整图语义向量和每个 patch 的局部向量。DINOv3 额外用 Gram anchoring 约束局部特征，避免训练久了 patch 之间变糊。

同一张图



局部小裁剪 → 学生网络 → CLS

整张图 → 老师网络 → CLS



两个 CLS 的输出分布要一致

为什么没有标签也能学到东西

只看到翅膀也要猜出整张图的表示——必须先“认出这是一只鸟”。CLS 输出的是“这张图属于哪一类”的分布，只是类是模型自己发明的，没有名字。

CLS 的注意力为什么落在主体上

背景换个裁剪就没了，鸟不会。CLS 要跨裁剪给出一致的总结，只能盯着稳定又决定“这是什么”的区域——后面找主体用的热图就是它，是训练目标的副产品。

01 · 跑通

Mac 本机复现

M1 Max 上加载 ViT-S 权重，做特征 PCA 可视化、前景 mask 和一个 Gradio Demo，三个模型并排对比。

02 · 定量

CUB-200 上 1000 张图

用官方前景 mask 计算 IoU，比较 DINOv2、DINOv2 + register 和 DINOv3 谁更会“找主体”。

03 · 下游

先找主体，再交给 ViT 分类

用 DINOv3 自动框出主体、裁剪放大，再喂给课上讲的 ViT-B/16；在 5 个细粒度数据集上和直接看原图比。

三步共用一条链路

输入图片



DINOv3 patch 特征



前景 mask · 对比官方标注算 IoU



框出主体 · 裁剪放大 → ViT 分类

三步围绕同一个问题：DINOv3 的局部特征是否更擅长分开主体和背景？如果是，这种能力能否帮到细粒度分类？

```
1 conda create -n dinov3 python=3.11
2 pip install torch torchvision timm gradio
```

```
1 import timm
2 model = timm.create_model(
3     "vit_small_patch16_dinov3.lvd1689m",
4     pretrained=True, num_classes=0).eval()
```

```
1 bash experiments/app/run.sh # 启动 Demo
```

Demo 中并排比较的三个模型

名称	结构	输入分辨率	说明
dinov2	ViT-S/14	448 px	上一代基线
dinov2_reg4	ViT-S/14 + reg4	448 px	对照组
dinov3	ViT-S/16	512 px	复现对象, 21M

环境

Python 3.11 + PyTorch。Mac 上用 MPS 后端推理，不需要 NVIDIA 显卡。


模型

通过 timm 直接加载公开权重，num_classes=0 表示只要特征、不要分类头。

运行

权重首次下载后缓存在本机；单张图三个模型并排推理约 1.5 秒。

复现基于官方仓库 commit 6876159。本机只跑 21M 的 ViT-S，不运行 7B 旗舰模型。



怎么看这张图


- 每行从左到右：原图、DINOv2、DINOv2 + register、DINOv3。青色轮廓是官方标注的鸟体。
- 热力图亮的地方，是模型做判断时主要依赖的区域。

看到了什么

- DINOv3 的亮区更集中在鸟身上，也更连成一片。
- 前两代在树枝、水面等背景上有更多零散的高响应。

注意

肉眼看四张图只是直观印象，下一页用 1000 张图片做统计。



左：不同背景复杂度下的前景 IoU；中：相邻 patch 的平滑度分布；右：按主体大小 × 背景复杂度分成 9 组，DINOv3 相对 DINOv2 的 IoU 差值

0.681

DINOv3 前景 IoU

DINOv2 为 0.560

9 / 9

分组全部领先

不是只靠某一类图片

0.949


邻域平滑度

相邻 patch 更一致

IoU 越高，自动得到的主体区域与官方 mask 重叠越多。DINOv3 比 DINOv2 高 **0.121**，且 9 个分组全部领先；但 DINOv2 + register 平滑度更高、IoU 反而略降，说明"特征更平滑"不等于"主体分得更好"。

实验设计：先找主体，再分类

DINOv3 不用标注框主体 → 裁剪放大 → 同一个 ViT-B/16 分类



NABirds 测试集随机抽样：红框 = DINOv3 自动框 (CLS 注意力阈值 + 最大连通块)，青框 = 官方标注；右下两张是失败例




三种输入，同一个分类器

- 原图：基线，ViT 自己看整张图
- DINOv3 自动框裁剪：全程不用任何标注
- 官方 bbox 裁剪：人工框，当作上界

自动框有多准（与官方 bbox 的 IoU）

数据集	CUB	Dogs	Cars	NABirds
平均 IoU	0.80	0.77	0.80	0.79
$\text{IoU} \geq 0.5$	97%	90%	98%	96%



定位是准的，但对一个 448 分辨率、已经看得清主体的 ViT，只有主体小的时候“先找再放大”才有增量。

不掉分


CUB / Dogs / Cars / IP102 上与原图差在 ± 0.3 以内，和 seed 噪声同量级（两个 seed 差 0.1~0.2）。

NABirds +1.4

89.8 $\rightarrow$ 91.1。五个数据集里鸟占图最小、背景最杂的一个。

自动框 $\approx$ 人工框

无标注的 DINOv3 框和官方 bbox 裁剪相差 ≤ 0.2 ，四个数据集都如此。



+3.7

鸟不到图片 15% 的那 20%

84.7 → 88.3, 一组就贡献了大半涨幅


+0.4 ~ +1.2

其余四组

主体越大, 裁剪能补的信息越少

同一个规律, 换个方式验证

把 CUB 的输入从 448 降到 224 (像素 ÷ 4, 等于让鸟变小), 原图 88.4, DINOv3 裁剪后 90.4 (+1.9), 接近 448 原图的 90.7。



GT: Northern Harrier (Adult male) (bird = 7% of image)
raw: Broad-winged Hawk (Adult) X
crop: Northern Harrier (Adult male) OK



GT: Hermit Warbler (bird = 7% of image)
raw: Yellow-throated Warbler X
crop: Hermit Warbler OK



GT: Orange-crowned Warbler (bird = 9% of image)
raw: Common Yellowthroat (Female/immature male) X
crop: Orange-crowned Warbler OK



GT: Merlin (bird = 2% of image)
raw: Peregrine Falcon (Immature) X
crop: Merlin OK

怎么看

- 每组左边是原图 + DINOv3 自动框 (红), 右边是裁剪后送进 ViT 的图。
- 四张图里鸟只占 2%~9%, 原图预测 (红字) 全错, 裁剪后 (绿字) 全对。

错在哪


- 错的都是"长得像的近缘种": 隼 → 游隼, 橙冠莺 → 黄喉地莺。
- 细粒度分类靠喙、眉纹、翅斑这些细节; 鸟只占几个 patch 时细节根本不在, 放大后才回来。

原图下模型不是"看错地方", 而是"看不清"。

方向二：主体看得清 → 只看 DINOv3 挑的 1/4

不裁剪、不放大，直接按 DINOv3 的注意力删掉大部分 patch

只喂 ViT 一部分 token: DINOv3 挑的 25% ≈ 全图, 随机挑的 25% 掉 7~13 个点



怎么做

patch embedding 之后，只把 DINOv3 注意力最高的 k 个 patch (加 CLS) 送进 Transformer，其余丢掉。
ViT 对 token 数没要求，模型结构不改。

25% ≈ 全图

CUB 90.1 vs 90.7 • NABirds 89.4 vs 89.8

注意力计算量降到 1/16，只掉 0.4~0.6

-7 / -13

同样 25%，改成随机挑

选得准不准，值 6~13 个百分点

"看得少"不掉分，"看错地方"才掉。裁剪换精度、挑 token 换算力，靠的都是主体在哪。

踩过的坑：框裁得太紧反而掉分

第一版直接用紧贴主体的框，CUB 上自动框 90.2、官方框只有 88.1，比原图还低。原因是细长框被拉成正方形变形，且丢掉了周围的环境线索。改成"补成正方形 + 外扩 15%"后，两者回到 90.6 / 90.9。

局限

① 主要结果只有 2 个 seed (NABirds 两次都是 +1.4, CUB/Dogs/Cars 两次都在 ± 0.4 内)，更小的差异不能当结论；② DINOv3 找框会被更显眼的东西带走（花、卡车、松鼠），NABirds 里约 4% 的图 IoU < 0.5 ；③ 找框本身要多跑一个 ViT-B，推理开销翻倍。

延伸：定位的价值取决于"预算"

主体小、分辨率低、只准看一部分 patch，是"分类器看不清"的三种情况，三种情况下 DINOv3 的定位都换成了准确率。把它接进课题组的两阶段方法 FAL-ViT、只保留 10% 的 patch 时，五个数据集平均涨 9.3 个点，是同一个规律的极端情形。

DINOv3 不用标注就能把主体框到人工水平。这个信息有两种用法：主体看不清时先找再放大换精度，主体看得清时只看它挑的 1/4 换算力。

Demo: 4 分钟现场演示

0:00

加载图片

打开 Gradio 页面，选一张 CUB 示例图，三个模型同时推理。

0:45

查看特征

看 PCA 着色图，同色区域代表特征相近，主体和背景是否分开。

1:45

比较 mask

把自动前景 mask 和官方标注叠在一起，直观看 IoU 差在哪。

3:00

换一张图

上传一张现场提供的图片，看没有标注时模型表现如何。

本地运行 • <http://127.0.0.1:8000> • 演示前已提前加载三个模型

Q&A

项目背景 · 运行方式 · 实验结果 · 局限与改进

它是什么

Meta 开源的自监督 ViT，不用标注就能输出通用视觉特征。

我们验证了什么

本机跑通 + 1000 张定量：DINOv3 更会分开主体和背景。

有什么用

两个方向：主体看不清 → 先找再放大（NABirds +1.4，小鸟 +3.7）；主体看得清 → 只看它挑的 1/4 token（不掉分，随机挑掉 7~13）。

DINOv3 利用无标签图片学习通用视觉特征。在我们的实验中，它最明显的优势不是分类更准，而是**不用标注就能找到图片主体**——看不清时换成精度，看得清时换成算力。

Backup：复现材料

课程要求	已完成内容	可核验材料
代码仓库	官方代码与固定 commit 6876159	本地 DINOv3 仓库
README 与运行步骤	环境、模型、Demo 启动说明	experiments/notes/
实验结果	定量表、曲线、可视化和失败记录	experiments/outputs/
展示材料	Slidev、PDF、现场 Demo	DINOv3-Talk/
小组成员	余官松、陈良宇、沈逸帆	具体分工按实际记录补充

此页作为备份，不进入 6 分钟主讲。提交前请按三位成员的实际工作补充贡献说明。